INF5103 — Devoir I : Analyse statistique de quatre jeux de données

LELE SIMO ELISEE BERTRAND — Session Automne 2026

1. Jeu 1 — Plateforme d'apprentissage en ligne

1.1 Taux de réussite global par méthode

Méthode A : 844 / 1200 = 70,3 % ; méthode B : 541 / 1200 = 45,1 % ; écart (A − B) = +25,2 points.

En se basant uniquement sur le taux de reussite globale, je recommanderais d'utiliser la methode d'apprentssage A qui obtient un taux de reussite plus eleve (+25.2 %)

1.2 Taux de réussite par méthode à l'intérieur de chaque niveau initial

En observant le tableau obtenu (voir notebook Tableau 1), on remarque que en calculant le taux de reussite pour chaque methode d'apprentissage par niveau_initial, que les pourcentage obtenus par les apprenant ayant suivi la methodes B sont plus eleve que ceux ayant suivi la methode A

1.3 Confrontation des questions 1 et 2 : rôle des effectifs

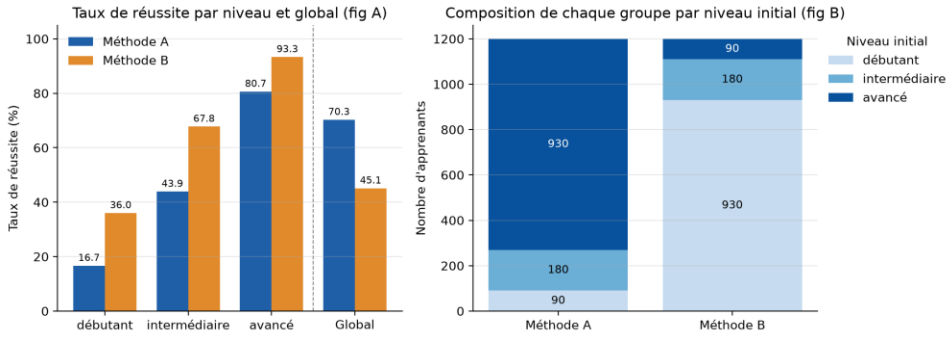


Figure 1 – (A) Taux de réussite par niveau et global ; (B) composition de chaque groupe par niveau initial

Les résultats globaux et les résultats par niveau initial mènent à des conclusions différentes. Si l'on se base uniquement sur le taux global de réussite, la méthode A devrait être recommandée comme méthode de référence. Cependant, en examinant les taux de réussite par niveau initial (fig. A), on constate que, pour chaque niveau, le taux de réussite de la méthode B est plus élevé que celui de la méthode A, même si la figure B montre que les deux méthodes ont le même effectif total. La différence provient d'un déséquilibre majeur dans l'affectation des apprenants (fig. B). La méthode A a testé une immense majorité d'élèves de niveau avancé (77,5 % de son groupe), qui ont naturellement un taux de réussite très élevé(80.7, 93.3). À l'inverse, la méthode B a été testée sur une majorité de débutants (77,5 %). Le taux global brut est donc biaisé par la composition des groupes.

1.4 Taux global standardisé

Poids : débutant 0,425 ; intermédiaire 0,150 ; avancé 0,425. Taux standardisé : A = 47,9 % ; B = 65,1 % (écart A − B = −17,2 points).

En calculant le taux de reussite pour chaque methode par niveau_initial en pondérant cette fois les taux par niveau par les effectifs de l'ensemble du groupe, on voit que les resultats obtenu apres standardisation sont nettement differents de ceux obtenu dans la section 1.1. Le taux brut initialement avantageux pour la méthode A (70,3 % contre 45,1 % pour B) tombe à un taux standardisé de 47,9 %. À l'inverse, le taux de réussite standardisé de la méthode B grimpe à 65,1 %, soit un gain net de +17,2 points de pourcentage en faveur de la méthode B. Ainsi, je recommanderais d'opter la methode d'apprentissage B.

1.5 Même démarche avec la variable region

Tableau 2 – Taux de réussite par région et par méthode

Région	A (%)	B (%)	Écart A – B	n A	n B
Hors Québec	69,5	44,0	25,5	341	309
Montréal	68,2	46,5	21,7	302	303
Outaouais	69,5	44,9	24,6	282	263
Québec	74,5	44,9	29,6	275	325

Pour chaque région sans exception (Hors Québec, Montréal, Outaouais, Québec), la méthode A surpasse systématiquement la méthode B, avec un écart positif stable oscillant entre +21,7 et +29,6 points de pourcentage. L'écart global brut de la question 1 (+25,2 points en faveur de A) se reflète de manière homogène dans chaque région. Etant donnes que les ecarts entre les personnes ayant suivi les methodes A et B par rapport a la region geographique sont en accord avec ceux obtenu a la section 1.1, on peut conclure que la variable region n'a aucune consequence sur l'efficacite relatif des methodes d'enseignement

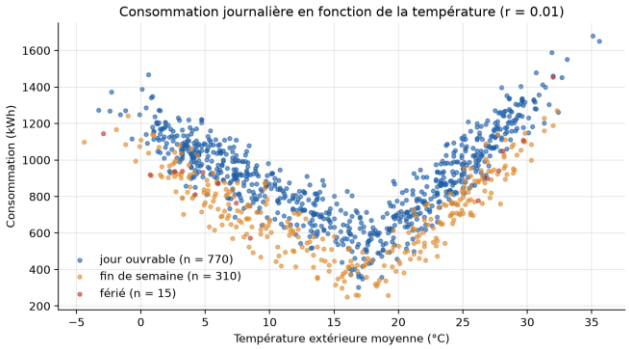
2. Jeu 2 — Consommation électrique d'un immeuble de bureaux

2.1 Coefficient de corrélation entre la température exterieure et la consommation

r (Pearson) = 0,012 ; r^2 = 0,000 (1095 journées).

La valeur du cofficient de correlation proche de zero indique qu'il n'existe aucune relation linéaire entre la temperature exterieur et la consommation.

2.2 et 2.3 Nuage de points et corrélation de part et d'autre d'un seuil



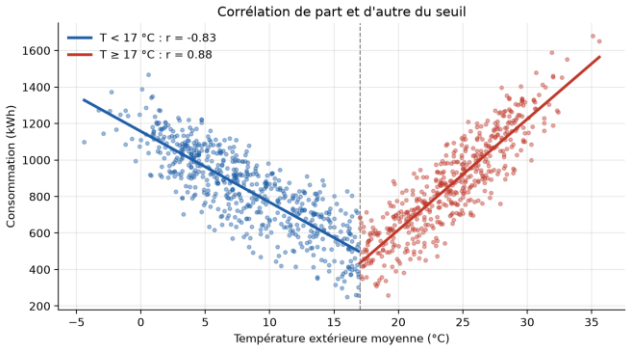


Figure 2 – Consommation en fonction de la température (r = 0,01)

Figure 3 – Corrélation de part et d'autre du seuil de 17 °C

La courbe demontre que pour les basse temperature(< 15), plus la temperature diminue, plus la consommation augmente et pour les temperature elevees(>16), plus la temperature augmente, plus la consommation augmente. Ce qui explique pourquoi le coefficient de correlation (Pearson) de la question 2.1 etais proche de zero car il n'est pertinent que dans le cas d'une relation lineaire

Tableau 3 – Corrélation dans chaque groupe

Groupe	Nombre de jours	r (température, consommation)
T < 17 °C	592	−0,826
T ≥ 17 °C	503	0,884
Toutes les journées (2.1)	1095	0,012

Le seuil de 17 a ete choisi car il marque le point d'intersection entre les tempeature chaude et froide. La division en deux groupe a permis de faire apparaître des relations linéaires très fortes qui étaient complètement masquées et annulées dans le calcul global de la question 2.1

la projection montre que la relation de part et d'autre du seuil (17 degre celsius) est linaire

2.4 Température à laquelle la consommation est minimal

Tranche de consommation moyenne minimale : [16 ; 18) °C, 512,7 kWh (70 jours).

Le tableau montre que au alentours de temperature 16-18 degre, la consommation d'energie est minimale. En comparant ces valeurs avec le nuage produit a la question 2.2, nous observons une forme U montrant que avant cette tranche de temperature, la consommation croit inversement avec la temperature et apres cette tranche de temperature, la relation est lineairement proportionel. Cela peut s'expliquer physiquement par l'activation du chauffage pour compenser les pertes thermiques lorsque les températures descendent en dessous de ce seuil, et par le démarrage de la climatisation pour évacuer la chaleur et refroidir l'immeuble dès que les températures le dépassent

2.5 Rôle du calendrier d'utilisation : occupation et jours fériés

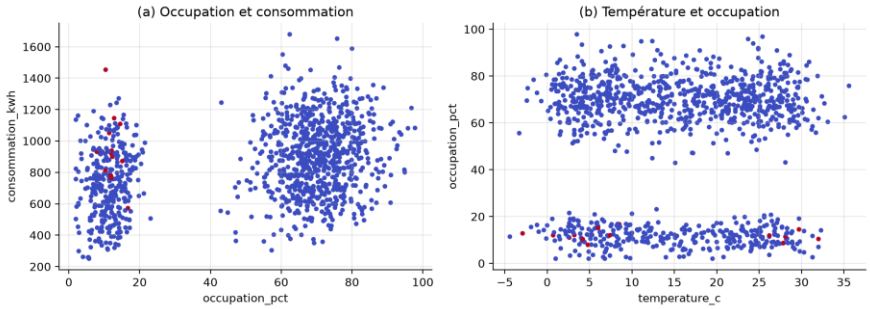


Figure 4 – (a) Occupation et consommation ; (b) température et occupation (points rouges : jours fériés)

D'après les résultats, le coefficient de corrélation linéaire entre le taux d'occupation et la consommation(r = 0,358, R^2 = 0,128) montre que le taux d'occupation du batiment explique 12,8% de la variance de la consommation électrique du bâtiment. Quant à la variable jours fériés, son impact linéaire direct est très faible (r = 0,042, R^2 = 0,002), ce qui s'explique par le fait qu'elle ne représente qu'une petite partie des observations de l'année. La consommation moyenne s'élève à 852,9 kWh les jours normaux contre 941,5 kWh les jours féries.

La verification de la corelation entre la tempoerature et les variables jours_ferie, occupation nous permets d'ecarter tout biais de confusion. Ainsi on peut voir que la temperature n'est pas corrélée à l'occupation du batiment (r = -0,004)ainsi que les jours fériés (r = -0,023)

2.6 Bilan sur l'usage du coefficient de corrélation

Il est a retenir qu'une valeur de coefficient de correlation entre deux variable proche de zero ne signifie pas forcement que les deux variable n'ont pas de relations. Comme on l'a vu dans la question 2.3, en separant les consommations en deux groupe selon un seuil de temoperature(17), deux droite,une pente négative(temperature basse) et une pente positive (temperature haute), ce qui n'etais pas identifiable dans la resultat obtenu de la question 2.1 (r = 0,012; coefficient de corelation entre les variables brutes de temperature et consommation) qui tendais a nous amener a croire qu'il n'existe pas de relation entre ces deux variable. Il est donc toujours indispensable de tracer un nuage de points avant d'interpréter un coefficient de corrélation, sous peine de passer à côté d'une structure de données non linéaire complexe mais essentielle pour comprendre le phénomène étudié

3. Jeu 3 — Dossiers de patients d'une clinique

3.1 Description statistique et détection des anomalies

Tableau 4 – Données brutes (800 lignes) : description et valeurs hors intervalle ; lignes identiques sauf l'identifiant : 15

Colonne	min	médiane	max	Intervalle plausible	Lignes hors intervalle	Valeurs rencontrées
age	18	52	999	[0 ; 120]	40	999
tension_systolique	−1	126	164	[60 ; 260]	25	−1
taille_cm	1,54	170,1	196,7	[100 ; 230]	30	1,54 à 1,87 (mètres)
poids_kg	37,0	76,25	121,1	[25 ; 300]	0	—

L'analyse statistique de base a permis de detecter des valeurs anormale; tension systolique invalide (min : -1), taille anormale (min 1.54) selon l'unite de mesure(s'agirait-il d'une erreur de conversion?), valeur age abberante (max a 999)

Une anomalie est détectée (15 lignes identiques sur toutes les colonnes sauf l'identifiant) qui sont très probablement des doublons, le même patient saisi deux fois sous deux numéros

En se basant sur mes des connaissance de bases (ex: il est logiquement impossible de trouver un etre humain de 18 ans et plus ayant moins de 1 metre), j'ai fixe des intervalle plausible afin de detecter et quantifier les donnes hors intervalle.

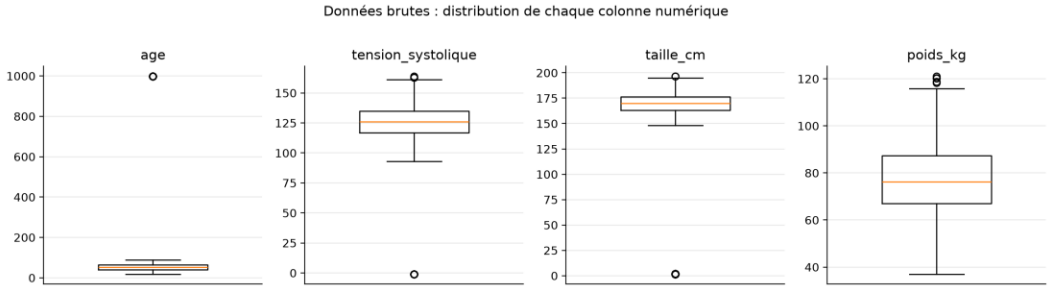


Figure 5 – Données brutes : distribution de chaque colonne numérique

Le box_plot illustre les valeurs aberrantes qui ecrasent les echelles des graphiques. Pour l'age, on voit que la majorite des patient ont un age normal (entre 0 et 200), on peut egalement identifier un point isolé tout en haut, à la valeur 999, ce qui confirme visuellement la présence de cette valeur aberrante. Concernant le plot de la tension_systolique, la distribution est egalement bien centre avec neamoins un point aberrant isolé tout en bas, proche de 0 (qui correspond aux valeurs à -1). Le graphe de la taille, on observe egalement que la boîte est bien positionnée autour de 170 cm, mais un point est écrasé tout en bas, proche de 0.Pour le poid en kg, on constate que c'est la seule variable qui presente distribution normal, ce qui appui le fait que nous n'ayons pas trouve de valeurs anormale par rapport au intervalle fixe (40-120 kg).

3.2 Préparation du jeu de données

Nous avons decide de retirer les lignes des variables age et tension_systolique dont certains valeurs etaient aberantes. En partant de l'hypothese qu'il y a eu une erreur dans la conversion, nous avons decide de multiplier par 100 toute valeur inferieur a 3. Ces changements ont resulte en un retrait de 65 lignes (ligne après = 800 – 65).Par ailleurs, concernant les doublons physiologiques détectés en 3.1 (hors identifiant unique), nous avons choisi de les conserver. L'IMC étant calculé uniquement à partir de la taille et du poids, il est statistiquement normal et attendu que plusieurs individus distincts de la population partagent exactement les mêmes mesures corporelles. Supprimer ces lignes reviendrait à fausser la distribution réelle de l'IMC de notre échantillon et à sous-estimer certaines classes de poids.

3.3 Moyenne et médiane de l'âge avant et après la préparation

Tableau 6 – Âge avant et après la préparation

	Avant	Après	Écart
moyenne	98,63	51,2	−47,43
médiane	52,00	51,0	−1,00

Le tableau de Bilan de la question 3.2 nous montre que 40 lignes ont ete retire a cause de la variable age, le box plot precedent (3.1) nous avait revele que la valeur abberante correspondait essentiellement a la donnee age=999(ces valeurs causent un ecart entre la moyenne et la medianne : 46.63), le reste des donnee etant centre s'étendant de 18 à 89 ans, la moitié centrale des patients ayant entre 41 et 61,5 ans. Une elimination de cette valeur aberrante a permis de retrouver une distribution dont la moyenne et la mediannne sont presque identique(ecart = 0,2).

3.4 Corrélation entre l'âge et la tension systolique, avant et après

r avant nettoyage = 0,051 ; r après nettoyage = 0,696.

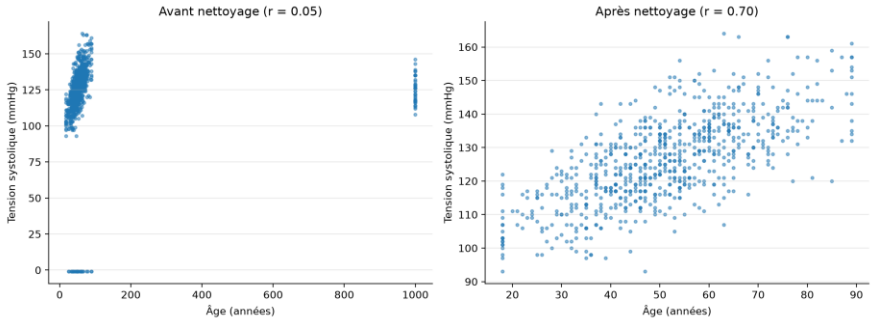


Figure 6 – Âge et tension systolique, avant et après nettoyage

En analysant les deux dot plot, nous constatons que pour le graphe avant nettoyage (r = 0,05), le coefficient de corrélation étant proche de 0, nous observons une ségrégation de groupes de points. Cela correspondrait d'une part à la ligne de points aberrants tout en bas (tensions codées à -1) et, d'autre part, au bloc de points rejeté à l'extrême droite (âges codés à 999), deux anomalies de saisie qui masquent complètement la véritable relation entre les deux variable. Quant au graphe apres nettoyage (r=0,70), nous constatons que la suppression de ces observations aberrantes fait disparaître cette ségrégation artificielle. Les points se regroupent désormais en un seul nuage homogène qui présente une tendance linéaire ascendante très nette. Cette forte hausse du coefficient de corrélation, qui passe de 0,05 à 0,70, confirme que l'élimination des codes d'erreurs réaligne mathématiquement les données avec la réalité clinique : la tension systolique augmente de manière constante et significative à mesure que les patients avancent en âge.

3.5 Tension systolique moyenne par classe d'IMC

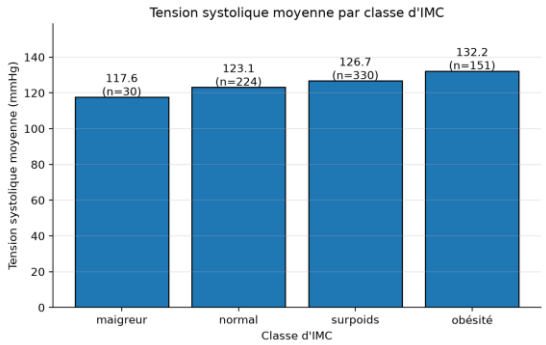


Figure 7 – Tension systolique moyenne par classe d'IMC

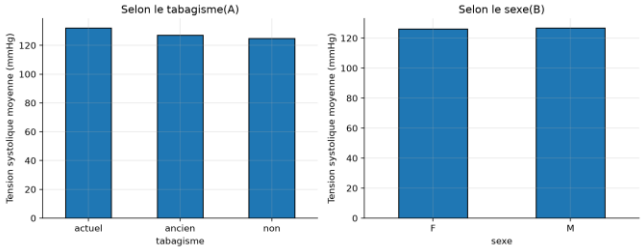


Figure 8 – Tension moyenne selon le tabagisme (A) et le sexe (B)

le bar plot suivant montre une progression lineaire et continue de la tension systolique moyenne par rapport au classe d'IMC, ce qui confirme un lien fort entre la masse corporelle et la pression arterielle.Le passage d'un IMC normal à un statut d'obésité se traduit par une hausse de tension moyenne d'environ 9,1mmHg, ce qui déplace la moyenne de cette catégorie au-delà du seuil de préhypertension (généralement fixé à 130 mmHg). L'indice de masse corporelle apparaît donc comme un facteur de risque majeur accompagnant une tension élevée au sein des patients.

3.6 Tension systolique selon le statut tabagique et selon le sexe

Les plots (plot 3.6 notebook)montrent la variation de la tension systolique par rapport au statut de tabagisme(A) et selon le sexe (B).En analysant le graphique, nous constatons que le statut tabagique montre une influence notable sur la pression artérielle. L'écart maximal entre les sous-groupes s'élève à environ 7,3 mmHg, la tension systolique moyenne la plus haute étant enregistrée chez les fumeurs actuels, suivis par les anciens fumeurs, tandis que les non-fumeurs présentent la moyenne la plus basse.Cet ecart notable(7,3mmHg) montre que la consommation de tabac est un facteur qui influence fortement la variation cliniinique de la tension au sein des patient.À l'inverse, en analysant le graphique de droite, nous constatons que la répartition par sexe ne montre pratiquement aucune ségrégation des données. Les barres des femmes (F) et des hommes (M) sont d'une hauteur presque identique, révélant un écart infime (0,7 mmHg). Cette différence négligeable démontre que le sexe n'exerce aucune influence sur la tension systolique moyenne des patients dans ce jeu de données.

4. Jeu 4 — Temps de réponse d'un service web

4.1 Moyenne, médiane, 95e centile

Les resultats obtenu dans le notebook montrent une enorme ecart entre la moyenne (58,2 ms) et la medianne(6,6 ms), ce qui explique que la majorite des requetes est ultra-rapide. La moyenne etant biaise (tiree vers le haut) par une longue traine de requete lente (materialise par un 95e centile a 288,1 ms). Le denombrement des requetes situees a moins de 10% de la moyenne (0.00%) montre qu'absolument aucun utilisateur n'experimente un temps de reponse proche de la moyenne qui est a 58.2 ms. Ces resultats nous montrent que la moyenne n'est pas toujours un resume statistiquement pertinent. Dans le cas du service web, elle n'est pas utile car elle ne reflete pas la realite du terrain contrairement a la mediane qui montre l'etat de la fluidite vecue par la majorite des requete.

4.2 Histogrammes en échelle linéaire et logarithmique

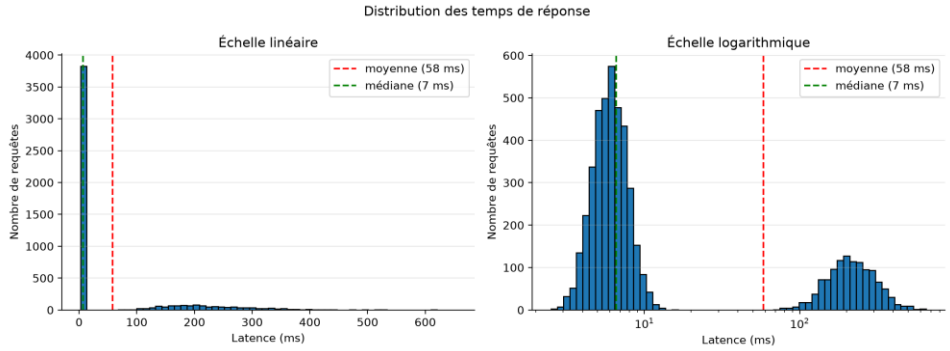


Figure 9 – Distribution des temps de réponse en échelle linéaire et logarithmique

Le graphique d'echelle lineaire montre un ecrasement de donnees sur la gauche, la distribution est fortement etale a droite(sommet ecrase pres de zero), la mediane se situant au centre du pic principal(7ms) et la moyenne deporte vers droite(58ms).Par contre, le graphe a l'echelle logarithmique devoile une segregation en plusieurs modes, on peut distinguer trois groupes de latence (un ultra rapide a envrons 5 ms, un groupe rapide intermedoiaire entre 10-20 ms et un troisieme groupe lent entre 100ms et plus.On conclue donc que la piremiere représentation linéaire s'avère inefficace, car elle masque complètement la structure interne des temps de réponse de l'immense majorité des utilisateurs.

4.3 Explication de la forme par les autres colonnes

(Voir tableau notebook : Latence selon chaque piste ; médiane par endpoint : ≈ 6,3 ms (2.3.1) contre ≈ 184 ms (2.4.0))

Pour la piste par endpoint, ont obtient que la repartion des requetes est homogene; la moyenne se situe entre 55,9 et 59,5ms et la mediane est a 6,6ms, cette piste a donc ete ecarte car la nature de la requete n'explique pas les differences de perfomance.Pour le parametre de l'heure, de 8 a 15heures, les valeurs restent egalement stables, la moyenne se situe entre 54.9 et 65.8 tandis que la mediane reste au alentours de 6.5, ce qui nous amene a conclure que l'heure de la journee n'est pas un parametre qui influence la latence. Par contre, en analysant les valeurs de la piste par version de service, on obtient un ecart importants entre les parametre de les donnees obtenu pour la version 2.3.1 (moyenne=31.6, mediane=6.3) et la version 2.4.0 (168.5ms, 183.6ms), ces resultats nous devoile que la structure multimodale observée sur l'histogramme s'explique intégralement par une régression majeure de performance introduite dans la version 2.4.0. La verification croisee endpoint x version service permet de confirmer que pour chaque point d'entree, la moyenne de temps de latence pour les requete effectues sous la version 2.3.1 est nettement plus petite que les requetes effectues sous version 2.4.0, ce qui conclu que la version 2.3.1 est la version la plus performante.

4.4 Choix d'un indicateur à surveiller

Indicateurs possibles (ms) : moyenne 58,2 ; médiane 6,6 ; 90e centile 227,5 ; 95e centile 288,1 ; 99e centile 384,1 ; maximum 653,1.

Pour surveiller ce service web, il est recommandé de choisir le 95e centile (288,1 ms) car cet indicateur standard de l'industrie est sensible aux ralentissements de la version 2.4.0 sans être perturbé par les valeurs maximales isolées, contrairement à une moyenne ou une médiane qui masquent la réalité de la distribution.